

Thema 5: Time Series Cross-Validation for Temporal Data

LaTeX-Uebersicht mit Definitionen und Projektvorgehen

Projektziel

Ziel der Projektarbeit ist es, verschiedene Cross-Validation-Verfahren fuer Zeitreihendaten systematisch zu vergleichen. Im Mittelpunkt steht die Frage, welches Verfahren bei zeitlich abhaengigen Daten die zuverlaessigsten Fehlerschaetzungen und Modellentscheidungen liefert.

Forschungsfrage

Welche Cross-Validation-Methode eignet sich fuer Forecasting-Aufgaben mit zeitlicher Abhaengigkeit am besten, wenn Modelle anhand ihres geschaetzten Vorhersagefehlers ausgewaehlt werden?

- k-fold Cross-Validation
- Leave-One-Out Cross-Validation (LOOCV)
- Rolling-Origin Cross-Validation
- Blocked Cross-Validation
- h-block Cross-Validation

Wichtige Definitionen

Definition: Zeitreihe

Eine Zeitreihe ist eine geordnete Folge von Beobachtungen $y_1, y_2, \dots, y_T$, bei der die Reihenfolge inhaltlich relevant ist. Beobachtungen koennen von vorherigen Werten abhaengen.

Definition: Forecasting-Modell

Ein Forecasting-Modell nutzt Informationen aus der Vergangenheit, um zukuenftige Werte zu prognostizieren, zum Beispiel $y_t = \beta_0 + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + \epsilon_t$.

Definition: Train-Test-Split fuer Zeitreihen

Die zeitliche Ordnung bleibt erhalten: die ersten T_{train} Beobachtungen dienen als Training, die letzten T_{test} Beobachtungen als unberuehrter Hold-out-Test.

Definition: Cross-Validation-Fehler

Der CV-Fehler ist der durchschnittliche Validierungsfehler ueber mehrere Splits. Er dient zur Schaetzung des spaeteren Vorhersagefehlers.

Definition: k-fold CV

Die Daten werden in K Folds geteilt. Jeder Fold wird einmal validiert. Bei Zeitreihen ist zufaellige Fold-Bildung kritisch, weil Zukunftsinformation ins Training gelangen kann.

Definition: LOOCV

Leave-One-Out CV ist k-fold CV mit $K = n$. Pro Split wird eine Beobachtung validiert. Bei abhaengigen Zeitpunkten kann das zu optimistischen Fehlerschaetzungen fuehren.

Definition: Rolling-Origin CV

Das Training verwendet nur vergangene Beobachtungen, das Validierungsfenster liegt danach. Das Trainingsfenster kann expandierend oder rollierend sein.

Definition: Blocked CV

Die Zeitreihe wird in zusammenhaengende Bloecke geteilt. Ganze Bloecke werden validiert, wodurch lokale zeitliche Struktur besser erhalten bleibt.

Definition: h-block CV

Zwischen Training und Validierung wird eine Luecke der Laenge h gelassen, um die Abhaengigkeit zwischen Trainings- und Validierungsdaten zu reduzieren.

Daten-generierende Prozesse

Prozess	Form	Idee
AR(1)	$y_t = \phi y_{t-1} + \epsilon_t$	Abhängigkeit vom vorherigen Wert
MA(q)	$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \dots$	Abhängigkeit von Schocks
ARMA(p,q)	AR-Komponente + MA-Komponente	Kombinierter Zeitreihenprozess
Trend/Saison	$\alpha + \gamma t + A \sin(2\pi t / s) + \epsilon_t$	Trend und periodische Muster

Kandidatenmodelle

- lineare Lag-Regression
- Ridge Regression mit Lags
- Lasso Regression mit Lags
- Regression Tree
- Random Forest oder anderes tree-based Modell

Lag-Features: $x_t = (y_{t-1}, y_{t-2}, \dots, y_{t-p})$.

Evaluationsgrößen

Hold-out-Testfehler: mittlerer Fehler auf den letzten, unberührten Beobachtungen.

$$\text{Err}_{\text{test}} = (1 / T_{\text{test}}) \sum_{t \text{ in Test}} (y_t - \hat{y}_t)^2$$

RMSE: Wurzel aus dem mittleren quadratischen Fehler.

$$\text{RMSE} = \sqrt{(1 / n) \sum_i (y_i - \hat{y}_i)^2}$$

Bias der Fehlerschätzung: durchschnittliche Differenz aus CV-Fehler und Testfehler.

$$\text{Bias} = (1 / R) \sum_r (\text{Err}_{\text{CV},r} - \text{Err}_{\text{test},r})$$

Varianz: Streuung der CV-Fehlerschätzung über alle Monte-Carlo-Wiederholungen.

Model-Selection Accuracy: Anteil der Simulationen, in denen CV das auf dem Testset beste Modell auswählt.

Genauer Arbeitsablauf

Phase 1: Theorie und Eingrenzung

1. Vorlesungsfolien zu Resampling Methods und Model Selection sichten.
2. Definitionen fuer k-fold, LOOCV, Rolling-Origin, Blocked CV und h-block CV formulieren.
3. Begründen, warum Standard-CV bei Zeitreihen problematisch sein kann.
4. Forschungsfrage und Vergleichskriterien final festlegen.

Phase 2: Simulationsdesign

1. Daten-generierende Prozesse festlegen: AR, MA, ARMA, Trend und Saisonalitaet.
2. Parameter festlegen, z.B. $T = 250$, $T_{\text{train}} = 175$, $T_{\text{test}} = 75$.
3. Monte-Carlo-Wiederholungen festlegen: erst $R = 20$ als Testlauf, danach z.B. $R = 500$.
4. Kandidaten-Lags definieren, z.B. p in $\{1, 2, 5, 10\}$.
5. h-Werte fuer h-block CV definieren, z.B. h in $\{1, 5, 10\}$.

Phase 3: Implementierung

1. Funktionen fuer die Simulation der DGPs schreiben.
2. Lag-Features erstellen.
3. CV-Splitter fuer alle Verfahren implementieren.
4. Modellfunktionen fuer lineare Regression, Ridge, Lasso und Tree-Based Methods bauen.
5. Evaluation fuer RMSE, Bias, Varianz, Accuracy und Laufzeit implementieren.

Phase 4: Smoke-Test

1. Sehr kleinen Testlauf ausfuehren: ein DGP, zwei Modelle, zwei CV-Verfahren, $R = 5$.
2. Pruefen, ob alle Splits zeitlich korrekt sind.
3. Pruefen, ob keine Daten aus der Zukunft ins Training gelangen.
4. Erste Ergebnisdatei speichern und kontrollieren.

Phase 5: Hauptsimulation

1. Alle DGPs und Parameterkombinationen durchlaufen.
2. Pro Simulation CV-Fehler je Verfahren und Modell berechnen.
3. Je CV-Verfahren das Modell mit kleinstem CV-Fehler auswaehlen.
4. Ausgewaehltes Modell auf dem Hold-out-Testset evaluieren.
5. CV-Fehler, Testfehler, Modellentscheidung und Laufzeit speichern.

Phase 6: Auswertung und Interpretation

1. Bias, Varianz, Test-RMSE, Model-Selection Accuracy und Laufzeit vergleichen.
2. Boxplots, Balkendiagramme, Tabellen und ggf. Heatmaps erstellen.
3. Trade-off zwischen Bias, Varianz und Laufzeit diskutieren.
4. Praktische Empfehlung fuer Forecasting-Probleme formulieren.

Geplanter Output

- reproduzierbarer Code fuer Simulation und Evaluation
- Tabellen mit Bias, Varianz, RMSE, Accuracy und Laufzeit
- Grafiken fuer Hausarbeit und Praesentation
- Hausarbeit mit Methodik, Ergebnissen und Fazit
- Praesentation mit klarer Empfehlung fuer die Anwendung

Kurze Erwartung

Es ist zu erwarten, dass zufaellige k-fold CV und LOOCV bei stark abhaengigen Zeitreihen zu optimistische Fehlerschaetzungen liefern koennen. Verfahren, die die zeitliche Ordnung explizit beruecksichtigen, insbesondere Rolling-Origin, Blocked CV und h-block CV, sollten realistischere Schaetzungen liefern. Welches Verfahren insgesamt am besten abschneidet, haengt von Autokorrelation, Trend/Saisonalitaet, Stichprobengroesse und Modellklasse ab.