

Statistical Learning

Prüfungsskript Ch. 1-5

Einführung, Statistical Learning, Lineare Regression, Classification, Resampling Methods

Ziel dieser Fassung: prüfungsorientierte Zusammenfassung der hochgeladenen Foliensätze mit Hintergrundinformationen, Formeln, Formelmechanik, Abhängigkeiten, Interpretationen und typischen Prüfungsfallen. Die Formeln werden nicht nur aufgelistet, sondern jeweils danach erklärt, *was wovon abhängt, warum die Formel so aussieht und wie man sie in Worten interpretiert.*

Erstellt auf Basis der hochgeladenen Foliensätze: Ch1 Introduction, Ch2 Statistical Learning, Ch3 Linear Regression, Ch4 Classification, Ch5 Resampling Methods.

6. Mai 2026

Inhaltsverzeichnis

1	Big Picture: Was macht Statistical Learning?	3
1.1	Notation und Grundmodell	3
1.2	Supervised vs. Unsupervised Learning	3
1.3	Regression vs. Classification	4
1.4	Statistical Learning vs. Machine Learning	4
2	Kapitel 2: Statistical Learning im Detail	4
2.1	Wozu ist $f(X)$ gut?	4
2.2	Die ideale Regressionsfunktion	5
2.3	Reducible und irreducible error	5
2.4	Schätzung von f : lokal mitteln und curse of dimensionality	5
2.5	Flexibilität, Interpretierbarkeit und Overfitting	5
2.6	Training Error und Test Error	6
2.7	Bias-Variance Trade-off	7
3	Kapitel 3: Lineare Regression	7
3.1	Warum lineare Regression trotz falscher Linearität wichtig ist	7
3.2	Simple Linear Regression	7
3.3	Residuen und RSS	8
3.4	Least Squares Schätzer	8
3.5	Standardfehler, Konfidenzintervall und t-Test	9
3.6	Modellgüte: RSE, TSS, R^2 und F-Test	10
3.7	Multiple Linear Regression	10
3.8	Variablenselektion	11
3.9	Qualitative Predictors und Dummy-Codierung	11
3.10	Interaktionen	11
3.11	Nichtlinearität durch Polynome	12
3.12	Nicht ausführlich behandelte, aber wichtige Diagnostik	12
4	Kapitel 4: Classification	12
4.1	Grundidee der Klassifikation	12
4.2	Bayes Classifier und Misclassification Error	12
4.3	Warum lineare Regression für Klassifikation nicht ideal ist	13
4.4	Logistische Regression	13
4.5	Maximum Likelihood in logistischer Regression	14
4.6	Multiple Logistic Regression	14
4.7	Case-Control Sampling	14
4.8	Multiclass Logistic Regression	15
4.9	Discriminant Analysis: generative Sicht	15
4.10	LDA bei einer Variable	15
4.11	LDA mit mehreren Variablen	16
4.12	QDA und Naive Bayes	16
4.13	Logistic Regression vs. LDA	17
4.14	K-Nearest Neighbors	17
5	Kapitel 5: Resampling Methods	17
5.1	Warum Resampling?	17
5.2	Training Error vs. Test Error nochmal	17
5.3	Validation Set Approach	18
5.4	K-fold Cross-Validation	18
5.5	LOOCV	19

5.6	Cross-Validation für Classification	19
5.7	Cross-Validation richtig und falsch	20
5.8	Bootstrap: Grundidee	20
5.9	Bootstrap-Standardfehler	21
5.10	Bootstrap-Beispiel: Portfolio-Allokation	21
5.11	Bootstrap Percentile Confidence Interval	22
5.12	Warum Bootstrap nicht ideal für Prediction Error ist	22
5.13	Block Bootstrap bei Zeitreihen	22
5.14	Pre-validation	22
5.15	Bootstrap vs. Permutation Tests	23
6	Formelkompass: Was hängt wovon ab?	23
7	Prüfungsmuster: Typische Fragen und Kernantworten	24
8	Mini-Glossar	25
9	Quellenbasis	25

1 Big Picture: Was macht Statistical Learning?

Statistical Learning versucht, aus Daten eine Struktur zu lernen. Man beobachtet eine Zielvariable Y und erklärende Variablen $X_1, \dots, X_p$. In den Folien wird das mit vielen Beispielen motiviert: medizinische Risikofaktoren, Spamfilter, Handschrifterkennung, Krebsdiagnostik, Lohn-/Einkommensdaten, Satellitenbilder, Netflix Prize und moderne datengetriebene Anwendungen. Der Kern ist immer: Aus beobachteten Beispielen soll eine Regel gelernt werden, die entweder gut vorhersagt oder erklärbar macht, welche Variablen relevant sind.

Zentrale Denkweise

Statistical Learning ist nicht nur "ein Modell fitten". Es besteht aus drei verbundenen Aufgaben:

1. **Prediction:** Wie gut kann ich neue Beobachtungen vorhersagen?
2. **Inference/Interpretation:** Welche Variablen hängen mit Y zusammen, in welcher Richtung und wie stark?
3. **Assessment:** Wie zuverlässig ist das Modell? Wie groß ist der Fehler auf neuen Daten? Wie unsicher sind Parameter?

1.1 Notation und Grundmodell

Grundmodell des Statistical Learning

$$Y = f(X) + \varepsilon, \quad X = (X_1, \dots, X_p).$$

Bedeutung:

- Y : Response, Outcome, dependent variable, target. Beispiel: Sales, Blutdruck, Einkommen, Default ja/nein.
- X : Feature-/Prädiktorvektor. Einzelne Variablen heißen Inputs, Regressors, Covariates, Features oder Independent Variables.
- $f(X)$: systematischer, aber unbekannter Zusammenhang zwischen X und Y .
- ε : Fehlerterm. Enthält Messfehler, Zufall, nicht beobachtete Ursachen und alles, was f nicht erklärt.

Mechanik: Das Modell trennt den erklärbaren Teil $f(X)$ vom nicht erklärbaren Rest ε . Gute Modelle versuchen f möglichst gut zu approximieren, aber ε bleibt teilweise unvermeidbar.

Im Advertising-Beispiel lautet die Idee:

$$\text{Sales} \approx f(\text{TV}, \text{Radio}, \text{Newspaper}).$$

Man fragt also nicht nur, ob jede einzelne Werbeform mit Sales korreliert, sondern ob die drei Variablen gemeinsam eine gute Vorhersagefunktion ergeben.

1.2 Supervised vs. Unsupervised Learning

	Supervised Learning	Unsupervised Learning
Datenstruktur	Man hat X und beobachtetes Y .	Man hat nur X , kein Ziel Y .
Ziel	Vorhersage oder Erklärung von Y .	Muster finden: Gruppen, Strukturen, Dimensionen.

Beispiele	Regression, Classification, Logistic Regression, LDA, KNN.	Clustering, PCA, Dimensionsreduktion.
Bewertung	Testfehler, MSE, Misclassification Rate.	Schwieriger, weil es kein wahres Y gibt.
Typische Prüfungsfrage	“Ist das Problem supervised?” Wenn ein Zielwert gelernt wird: ja.	“Ist es unsupervised?” Wenn nur Struktur in X gesucht wird: ja.

1.3 Regression vs. Classification

- **Regression:** Y ist quantitativ, zum Beispiel Sales, Preis, Blutdruck, Einkommen. Ziel: Zahlenwert vorhersagen.
- **Classification:** Y ist qualitativ/kategorial, zum Beispiel Spam/Ham, Default yes/no, Krankheitstyp, Ziffer 0–9. Ziel: Klasse oder Klassenwahrscheinlichkeit vorhersagen.

Prüfungsfälle

Die Begriffe Regression und Classification beziehen sich auf die Art von Y , nicht auf die Art von X . Man kann kategoriale Prädiktoren in einer Regression verwenden und quantitative Prädiktoren in einer Klassifikation.

1.4 Statistical Learning vs. Machine Learning

Historisch entstand Machine Learning stärker aus Artificial Intelligence, Statistical Learning stärker aus Statistik. Machine Learning betont oft große Anwendungen, Skalierung und Prediction Accuracy. Statistical Learning betont stärker Modellstruktur, Interpretierbarkeit, Präzision und Unsicherheit. Heute überschneiden sich beide Felder stark. Für die Prüfung ist wichtig: Der Kurs verwendet Machine-Learning-Methoden, aber mit statistischer Denkweise, also immer mit Blick auf Fehler, Unsicherheit, Bias, Varianz und Modellannahmen.

2 Kapitel 2: Statistical Learning im Detail

2.1 Wozu ist $f(X)$ gut?

Eine gute Schätzung $\hat{f}$ erfüllt drei Funktionen:

1. **Vorhersage:** Für neue Werte $X = x$ kann man $\hat{y} = \hat{f}(x)$ berechnen.
2. **Variablenwichtigkeit:** Man erkennt, welche X_j stark mit Y zusammenhängen und welche kaum relevant sind.
3. **Wirkungsverständnis:** Bei interpretierbaren Modellen kann man beschreiben, wie X_j auf Y wirkt.

2.2 Die ideale Regressionsfunktion

Optimale Vorhersagefunktion bei quadratischem Verlust

$$f(x) = \mathbb{E}(Y \mid X = x).$$

Bedeutung: Der beste theoretische Predictor für Y bei gegebenem $X = x$ ist der bedingte Erwartungswert von Y unter allen Beobachtungen mit diesem $X = x$.

Mechanik: Wenn man quadratische Fehler minimiert, ist der Mittelwert optimal. Daher ist $\mathbb{E}(Y \mid X = x)$ die Funktion, die im Durchschnitt den kleinsten quadratischen Vorhersagefehler liefert.

Wovon hängt $f(x)$ ab?

- von der wahren Daten erzeugenden Beziehung zwischen X und Y ,
- von allen relevanten Prädiktoren,
- nicht von einem konkreten Trainingsdatensatz - f ist die Populationsfunktion.

In echten Daten kennen wir f nicht. Wir schätzen nur $\hat{f}$. Der Unterschied zwischen f und $\hat{f}$ ist eine zentrale Fehlerquelle.

2.3 Reducible und irreducible error

Fehlerzerlegung bei Vorhersage

$$\mathbb{E} \left[(Y - \hat{f}(X))^2 \mid X = x \right] = \left[f(x) - \hat{f}(x) \right]^2 + \text{Var}(\varepsilon).$$

Bestandteile:

- $\left[f(x) - \hat{f}(x) \right]^2$: reduzierbarer Fehler. Wenn $\hat{f}$ besser wird, kann dieser Term kleiner werden.
- $\text{Var}(\varepsilon)$: irreduzierbarer Fehler. Selbst bei perfekter Kenntnis von f bleibt Zufall/Messfehler übrig.

Mechanik: Das Modell kann nur den systematischen Teil erklären. Sobald zwei Personen/-Objekte mit gleichem X unterschiedliche Y -Werte haben, bleibt Restvariation.

Prüfungsformulierung: Kein Modell kann den gesamten Fehler eliminieren. Selbst das optimale Modell hat noch den irreducible error.

2.4 Schätzung von f : lokal mitteln und curse of dimensionality

Eine intuitive Schätzung ist:

$$\hat{f}(x) = \text{Ave}(Y \mid X \in N(x)),$$

wobei $N(x)$ eine Nachbarschaft von x ist.

Mechanik: Man sucht Beobachtungen, deren X -Werte ähnlich zu x sind, und mittelt deren Y -Werte. Das funktioniert gut bei wenigen Dimensionen, aber schlecht bei vielen Prädiktoren.

Curse of dimensionality

In hohen Dimensionen sind Punkte selten wirklich nahe beieinander. Wenn man genügend Nachbarn sucht, muss die Nachbarschaft groß werden. Dann ist sie nicht mehr lokal. Dadurch können flexible lokale Methoden instabil oder ungenau werden.

2.5 Flexibilität, Interpretierbarkeit und Overfitting

Modelltyp	Vorteil	Problem
Lineares Modell	Einfach interpretierbar, stabile Schätzung, gute Basis.	Hoher Bias, wenn wahre Beziehung stark nichtlinear ist.
Flexible Splines/GAMs	Können Nichtlinearität modellieren.	Weniger direkt interpretierbar, Gefahr von Overfitting.
Sehr flexible Modelle	Sehr niedriger Trainingsfehler.	Lernen Rauschen, hohe Varianz, schlechter Testfehler möglich.
Black-Box-Modelle	Oft gute Vorhersage.	Mechanismus schwer erklärbar, Inferenz schwieriger.

Overfitting in einem Satz

Overfitting bedeutet: Das Modell passt nicht nur die systematische Struktur, sondern auch den Zufall der Trainingsdaten. Es sieht im Training sehr gut aus, generalisiert aber schlecht.

2.6 Training Error und Test Error

Training MSE

$$\text{MSE}_{Tr} = \text{Ave}_{i \in Tr} \left[y_i - \hat{f}(x_i) \right]^2.$$

Mechanik: Man verwendet dieselben Daten zum Fitten und zum Bewerten. Deshalb ist dieser Fehler oft zu optimistisch.

Abhängigkeiten:

- steigt meist nicht, wenn das Modell flexibler wird;
- kann bei sehr flexiblen Modellen fast null werden;
- ist kein guter alleiniger Indikator für neue Daten.

Test MSE

$$\text{MSE}_{Te} = \text{Ave}_{i \in Te} \left[y_i - \hat{f}(x_i) \right]^2.$$

Mechanik: Das Modell wird auf Trainingsdaten geschätzt, aber auf unabhängigen Testdaten bewertet. Das misst Generalisierungsfähigkeit.

Abhängigkeiten:

- sinkt zunächst mit Flexibilität, wenn echter Bias abgebaut wird;
- steigt wieder, wenn Varianz/Overfitting dominiert;
- hat oft eine U-Form in Abhängigkeit der Modellkomplexität.

2.7 Bias-Variance Trade-off

Bias-Variance-Zerlegung

$$\mathbb{E} \left(y_0 - \hat{f}(x_0) \right)^2 = \text{Var} \left(\hat{f}(x_0) \right) + \left[\text{Bias} \left(\hat{f}(x_0) \right) \right]^2 + \text{Var}(\varepsilon).$$

$$\text{Bias} \left(\hat{f}(x_0) \right) = \mathbb{E}[\hat{f}(x_0)] - f(x_0).$$

Bedeutung: Der erwartete Testfehler besteht aus Varianz des Schätzers, quadriertem Bias und irreduziblem Fehler.

Mechanik:

- **Bias:** systematischer Fehler. Ein zu starres Modell trifft die wahre Struktur nicht.
- **Variance:** Empfindlichkeit gegenüber der Trainingsstichprobe. Ein zu flexibles Modell schwankt stark zwischen Stichproben.
- **Irreducible error:** bleibt immer.

Was passiert bei steigender Flexibilität?

- Bias sinkt meistens, weil das Modell mehr Formen darstellen kann.
- Varianz steigt meistens, weil das Modell stärker auf Trainingszufall reagiert.
- Testfehler ist minimal, wo die Summe aus Bias² und Varianz am besten ausbalanciert ist.

Typische Prüfungsfrage

Warum ist der Trainingsfehler bei $K = 1$ KNN oft sehr klein, aber der Testfehler nicht unbedingt? Weil $K = 1$ maximal flexibel ist: Jeder Trainingspunkt klassifiziert sich selbst perfekt, aber die Entscheidungsgrenze ist sehr wackelig und hat hohe Varianz.

3 Kapitel 3: Lineare Regression

3.1 Warum lineare Regression trotz falscher Linearität wichtig ist

Lineare Regression nimmt an:

$$\eta(x) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

Die Folien betonen: Wahre Funktionen sind fast nie exakt linear. Trotzdem ist lineare Regression extrem nützlich, weil sie interpretierbar, rechnerisch einfach, stabil und eine Grundlage vieler späterer Methoden ist.

3.2 Simple Linear Regression

Einfaches lineares Regressionsmodell

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

Bedeutung:

- β_0 : Intercept, erwarteter Wert von Y , wenn $X = 0$.
- β_1 : Steigung, erwartete Änderung von Y bei einer Einheit mehr in X .
- ε : Fehlerterm, alles was nicht durch die Gerade erklärt wird.

Mechanik: Die Gerade ist eine lineare Approximation. Jeder Punkt wird in einen erklärten Teil $\beta_0 + \beta_1 X$ und ein Residuum ε zerlegt.

Vorhersage

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Mechanik: Das Dach zeigt Schätzung. $\hat{\beta}_0$ und $\hat{\beta}_1$ kommen aus den Trainingsdaten. Für einen neuen Wert x setzt man diesen in die geschätzte Gerade ein.

3.3 Residuen und RSS**Residuum und RSS**

$$e_i = y_i - \hat{y}_i, \quad \text{RSS} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

Bedeutung:

- e_i : vertikaler Abstand zwischen beobachtetem Punkt und Regressionsgerade.
- RSS: Summe der quadrierten Residuen.

Mechanik: Quadrieren bewirkt drei Dinge: negative und positive Fehler heben sich nicht auf; große Fehler werden stark bestraft; die Optimierung wird mathematisch gut lösbar.

Abhängigkeiten:

- Je näher die Punkte an der Gerade liegen, desto kleiner RSS.
- Outlier können RSS stark vergrößern, weil Fehler quadriert werden.
- Ein komplexeres Modell kann RSS im Training fast immer senken, aber nicht automatisch Testfehler.

3.4 Least Squares Schätzer**OLS-Schätzer in einfacher Regression**

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Mechanik der Steigung:

- Zähler: gemeinsame Abweichung von X und Y um ihre Mittelwerte. Wenn hohe X -Werte mit hohen Y -Werten zusammenfallen, wird der Zähler positiv.
- Nenner: Streuung von X . Wenn X stark variiert, ist eine gegebene Covariation relativ weniger steil.
- $\hat{\beta}_1$ ist daher ungefähr "Covariance durch Variance".

Mechanik des Intercepts:

- Die Least-Squares-Gerade geht durch den Punkt $(\bar{x}, \bar{y})$.
- Daher muss $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ gelten.

Abhängigkeiten:

- Wenn X und Y positiv zusammen variieren, ist $\hat{\beta}_1 > 0$.
- Wenn X und Y negativ zusammen variieren, ist $\hat{\beta}_1 < 0$.
- Wenn X kaum streut, wird die Steigung instabil, weil der Nenner klein ist.

3.5 Standardfehler, Konfidenzintervall und t-Test

Standardfehler der Koeffizienten

$$\text{SE}(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \text{SE}(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

Mechanik:

- Mehr Rauschen σ^2 macht Koeffizienten unsicherer.
- Mehr Streuung in X macht die Steigung präziser, weil man mehr Hebel zur Schätzung der Beziehung hat.
- Größeres n stabilisiert besonders den Intercept.

Merksatz: Standardfehler misst nicht Modellfehler eines einzelnen Punktes, sondern Unsicherheit des geschätzten Parameters bei wiederholtem Sampling.

95%-Konfidenzintervall

$$\hat{\beta}_1 \pm 2 \cdot \text{SE}(\hat{\beta}_1).$$

Mechanik: Schätzung plus/minus Unsicherheitsbreite. Je größer der Standardfehler, desto breiter das Intervall.

Interpretation: Bei vielen wiederholten Stichproben würden ungefähr 95% der so konstruierten Intervalle den wahren Parameter enthalten. Nicht: "Der wahre Wert liegt mit 95% Wahrscheinlichkeit in diesem konkreten Intervall" - im frequentistischen Sinn ist der Parameter fix.

t-Statistik für $H_0 : \beta_1 = 0$

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)}.$$

Mechanik: Der Koeffizient wird in Einheiten seines Standardfehlers gemessen. Ein großer absoluter t-Wert bedeutet: Die geschätzte Steigung ist groß relativ zu ihrer Unsicherheit.

Abhängigkeiten:

- großer Effekt $\Rightarrow$ großer $|t|$, wenn SE konstant bleibt;
- kleiner SE $\Rightarrow$ großer $|t|$, auch bei moderatem Effekt;
- hoher p-Wert kann bedeuten: kein Effekt oder zu wenig Präzision/Daten.

Signifikanz ist nicht Kausalität

Ein kleiner p-Wert zeigt statistische Evidenz gegen H_0 . Er beweist aber nicht, dass X Y kausal verursacht. Dafür braucht man Design-/Identifikationsargumente.

3.6 Modellgüte: RSE, TSS, R^2 und F-Test

Residual Standard Error

$$\text{RSE} = \sqrt{\frac{1}{n-2} \text{RSS}} = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

Mechanik: RSE ist die typische Größe der Residuen in Originaleinheiten von Y . Man teilt durch $n-2$, weil bei einfacher Regression zwei Parameter geschätzt wurden.

Abhängigkeiten:

- größerer RSS $\Rightarrow$ größerer RSE;
- mehr Freiheitsgrade stabilisieren die Schätzung;
- bei multipler Regression wird $n-p-1$ verwendet.

TSS und R^2

$$\text{TSS} = \sum_{i=1}^n (y_i - \bar{y})^2, \quad R^2 = \frac{\text{TSS} - \text{RSS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}.$$

Mechanik:

- TSS: Gesamtvariation von Y um den Mittelwert.
- RSS: nicht erklärte Restvariation nach dem Modell.
- TSS – RSS: erklärte Variation.

Interpretation: R^2 ist der Anteil der Variation in Y , den das Modell relativ zum Mittelwertmodell erklärt.

Abhängigkeiten und Fallen:

- Mehr Prädiktoren senken RSS im Training fast immer, also steigt R^2 meistens.
- Hohes R^2 bedeutet nicht automatisch kausal oder gutes Testverhalten.
- Für Modellvergleich mit unterschiedlicher Prädiktorzahl ist adjusted R^2 , AIC/BIC oder CV oft besser.

3.7 Multiple Linear Regression

Multiple Regression

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon.$$

Interpretation von β_j : erwartete Änderung in Y , wenn X_j um eine Einheit steigt, *holding all other predictors fixed*.

Mechanik: Jeder Koeffizient ist ein partieller Effekt. Er beschreibt nicht den einfachen Zusammenhang zwischen X_j und Y , sondern den Zusammenhang nach Kontrolle der anderen Variablen.

Abhängigkeiten:

- Wenn Prädiktoren stark korreliert sind, werden Koeffizienten und SEs instabil.
- Ein Prädiktor kann bivariat wichtig aussehen, aber multivariat unwichtig werden, wenn seine Information schon in anderen Variablen steckt.
- Umgekehrt kann ein Effekt erst nach Kontrolle anderer Variablen sichtbar werden.

3.8 Variablenselektion

Methoden	Mechanik	Problem/Vorteil
Best subsets	Alle 2^p Modelle werden betrachtet.	Exakt, aber bei großem p rechnerisch unmöglich.
Forward selection	Start mit Nullmodell; füge schrittweise Variable hinzu, die RSS am stärksten senkt.	Effizienter, aber greedy; findet nicht garantiert global bestes Modell.
Backward selection	Start mit vollem Modell; entferne schrittweise unwichtigste Variable.	Braucht $n > p$; kann bei vielen Variablen problematisch sein.
AIC/BIC/Cp/adj. R^2 /CV	Wählen Modell mit Fehler-Komplexitäts-Kompromiss.	Besser als reines Training-RSS, weil Modellgröße bestraft wird.

3.9 Qualitative Predictors und Dummy-Codierung

Binärer Dummy

$$x_i = \begin{cases} 1, & \text{wenn Person } i \text{ weiblich ist,} \\ 0, & \text{wenn Person } i \text{ männlich ist.} \end{cases}$$

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i = \begin{cases} \beta_0 + \beta_1 + \varepsilon_i, & \text{weiblich,} \\ \beta_0 + \varepsilon_i, & \text{männlich.} \end{cases}$$

Mechanik:

- β_0 ist der Mittelwert der Referenzgruppe ($x = 0$).
- β_1 ist die Differenz der Gruppe ($x = 1$) zur Referenzgruppe.

Bei K Kategorien verwendet man normalerweise $K - 1$ Dummy-Variablen. Die ausgelassene Kategorie ist die Baseline. Man lässt eine Kategorie weg, um perfekte Multikollinearität zu vermeiden.

3.10 Interaktionen

Interaktionsmodell Advertising

$$sales = \beta_0 + \beta_1 TV + \beta_2 radio + \beta_3 (TV \times radio) + \varepsilon.$$

$$sales = \beta_0 + (\beta_1 + \beta_3 radio) TV + \beta_2 radio + \varepsilon.$$

Mechanik: Der Effekt von TV ist nicht mehr nur β_1 , sondern $\beta_1 + \beta_3 radio$. Das heißt: Die Steigung von TV hängt vom Radio-Budget ab.

Abhängigkeiten:

- Wenn $\beta_3 > 0$, wird der TV-Effekt größer, je höher radio ist.
- Wenn $\beta_3 < 0$, wird der TV-Effekt kleiner, je höher radio ist.
- Wenn $\beta_3 = 0$, gibt es keine Interaktion; das additive Modell reicht bezüglich dieses Terms.

Prüfungsfalle: Bei Interaktionen Haupteffekte nicht isoliert interpretieren. β_1 ist der TV-Effekt nur bei $radio = 0$.

3.11 Nichtlinearität durch Polynome

Polynomial Regression

$$mpg = \beta_0 + \beta_1 horsepower + \beta_2 horsepower^2 + \varepsilon.$$

Mechanik: Das Modell ist nichtlinear in *horsepower*, aber linear in den Parametern β . Deshalb ist es weiterhin ein lineares Modell im regressionsmethodischen Sinn.

Marginaler Effekt:

$$\frac{\partial mpg}{\partial horsepower} = \beta_1 + 2\beta_2 horsepower.$$

Abhängigkeit: Der Effekt von *horsepower* ist nicht konstant. Er hängt vom aktuellen *horsepower*-Wert ab.

3.12 Nicht ausführlich behandelte, aber wichtige Diagnostik

- **Outliers:** ungewöhnliche Y -Werte; können RSS stark beeinflussen.
- **Non-constant variance / Heteroskedastizität:** Fehlerstreuung hängt von X ab; SEs können falsch sein.
- **High leverage points:** ungewöhnliche X -Werte; können die Gerade stark ziehen.
- **Collinearity:** Prädiktoren sind stark korreliert; Koeffizienten werden instabil.

4 Kapitel 4: Classification

4.1 Grundidee der Klassifikation

Bei Klassifikation nimmt Y Werte in einer ungeordneten Menge $\mathcal{C}$ an, zum Beispiel $\{spam, ham\}$, $\{default, no\ default\}$, $\{0, 1, \dots, 9\}$. Gesucht ist eine Funktion

$$C(X) \in \mathcal{C}.$$

Oft sind Wahrscheinlichkeiten wichtiger als harte Klassen:

$$\Pr(Y = k \mid X = x).$$

Beispiel: Bei Versicherungsbetrug ist eine geschätzte Betrugswahrscheinlichkeit informativer als nur "Fraud"/"Not Fraud".

4.2 Bayes Classifier und Misclassification Error

Conditional Class Probabilities und Bayes Classifier

$$p_k(x) = \Pr(Y = k \mid X = x), \quad k = 1, \dots, K.$$

$$C(x) = j \quad \text{falls} \quad p_j(x) = \max\{p_1(x), \dots, p_K(x)\}.$$

Mechanik: Der Bayes Classifier wählt die Klasse mit der höchsten bedingten Wahrscheinlichkeit.

Bei zwei Klassen: Wähle Klasse 1, wenn $\Pr(Y = 1 \mid X = x) > 0.5$. Die Grenze, an der die Wahrscheinlichkeit genau 0.5 ist, heißt Bayes decision boundary.

Abhängigkeiten:

- Hängt von den wahren bedingten Klassenwahrscheinlichkeiten ab.
- Ist theoretisch optimal, aber praktisch unbekannt.
- Jede Methode versucht indirekt, diese Entscheidung möglichst gut zu approximieren.

Test Misclassification Error

$$Err_{Te} = \text{Ave}_{i \in Te} I[y_i \neq \hat{C}(x_i)].$$

Mechanik: $I[\cdot]$ ist 1 bei falscher Klassifikation und 0 bei richtiger. Der Durchschnitt ist der Anteil falsch klassifizierter Testfälle.

Prüfungsfalle: Ein Modell kann gute Wahrscheinlichkeiten liefern, aber bei falschem Cutoff schlechte Klassifikation. Klassifikation und Probability Estimation sind verwandt, aber nicht identisch.

4.3 Warum lineare Regression für Klassifikation nicht ideal ist

Bei binärem $Y \in \{0, 1\}$ gilt zwar:

$$\mathbb{E}(Y \mid X = x) = \Pr(Y = 1 \mid X = x).$$

Man könnte also linear regressieren und bei $\hat{y} > 0.5$ Klasse 1 vorhersagen. Problem: Lineare Regression kann Werte kleiner 0 oder größer 1 liefern. Für Wahrscheinlichkeiten ist das unmöglich. Bei mehr als zwei Klassen erzeugt numerische Kodierung zudem künstliche Ordnung und Abstände.

4.4 Logistische Regression**Logistische Funktion**

$$p(X) = \Pr(Y = 1 \mid X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}.$$

Mechanik: Der lineare Index $\eta = \beta_0 + \beta_1 X$ kann jeden Wert von $-\infty$ bis $+\infty$ annehmen. Die logistische Funktion transformiert ihn auf das Intervall $(0, 1)$.

Abhängigkeiten:

- Wenn η steigt, steigt $p(X)$.
- Für sehr negative η geht p gegen 0.
- Für sehr positive η geht p gegen 1.
- Die stärkste Änderung der Wahrscheinlichkeit passiert ungefähr bei $p = 0.5$.

Logit / Log-Odds

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X.$$

Bedeutung: Logistische Regression ist linear auf der Log-Odds-Skala, nicht auf der Wahrscheinlichkeitsskala.

Mechanik:

- $\frac{p}{1-p}$ sind Odds.
- Log-Odds können jeden reellen Wert annehmen.
- β_1 ist Änderung der Log-Odds pro Einheit X .

Odds Ratio

$$OR = e^{\beta_1}.$$

Mechanik: Bei einer Einheit mehr in X werden die Odds mit e^{β_1} multipliziert.

Interpretation:

- $OR > 1$: Odds steigen.
- $OR < 1$: Odds sinken.
- $OR = 1$: keine Änderung der Odds.

Prüfungsfalle: Odds Ratio ist nicht dasselbe wie Wahrscheinlichkeitsänderung. Die Wahrscheinlichkeitsänderung hängt vom Ausgangsniveau ab.

4.5 Maximum Likelihood in logistischer Regression**Likelihood für binäre logistische Regression**

$$\ell(\beta_0, \beta) = \prod_{i:y_i=1} p(x_i) \prod_{i:y_i=0} (1 - p(x_i)).$$

Mechanik: Für Beobachtungen mit $y_i = 1$ soll $p(x_i)$ groß sein. Für Beobachtungen mit $y_i = 0$ soll $1 - p(x_i)$ groß sein. Maximum Likelihood wählt Parameter, die die beobachteten Klassen am wahrscheinlichsten machen.

Warum nicht OLS? Weil Y binär ist, Wahrscheinlichkeiten beschränkt sind und die Fehlerstruktur nicht normal-homoskedastisch wie im klassischen linearen Modell ist.

4.6 Multiple Logistic Regression**Mehrere Prädiktoren**

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

Interpretation: β_j ist der Effekt von X_j auf die Log-Odds, wenn alle anderen Variablen konstant gehalten werden.

Mechanik: Genau wie bei multipler linearer Regression sind die Effekte partiell. Hinzufügen von Kontrollvariablen kann Koeffizienten verändern.

4.7 Case-Control Sampling**Intercept-Korrektur bei Case-Control Sampling**

$$\hat{\beta}_0^* = \hat{\beta}_0 + \log \frac{\pi}{1 - \pi} - \log \frac{\tilde{\pi}}{1 - \tilde{\pi}}.$$

Bedeutung:

- π : wahre Populationsprävalenz der Fälle.
- $\tilde{\pi}$: Fallanteil in der Stichprobe.
- $\hat{\beta}_0^*$: aus Case-Control-Daten geschätzter Intercept.

Mechanik: Bei Case-Control-Stichproben werden Fälle oft überrepräsentiert. Das verändert das Baseline-Risiko, also den Intercept. Die Steigungsparameter können unter korrektem Modell aber sinnvoll geschätzt werden.

Abhängigkeit: Je stärker $\tilde{\pi}$ von π abweicht, desto stärker muss der Intercept korrigiert werden.

4.8 Multiclass Logistic Regression

Softmax / multinomiale logistische Regression

$$\Pr(Y = k \mid X) = \frac{e^{\beta_{0k} + \beta_{1k}X_1 + \dots + \beta_{pk}X_p}}{\sum_{\ell=1}^K e^{\beta_{0\ell} + \beta_{1\ell}X_1 + \dots + \beta_{p\ell}X_p}}.$$

Mechanik: Jede Klasse bekommt einen linearen Score. Durch Exponentieren werden Scores positiv. Durch Division durch die Summe werden sie zu Wahrscheinlichkeiten, die sich zu 1 addieren.

Abhängigkeiten:

- Eine Klasse wird wahrscheinlicher, wenn ihr Score relativ zu den anderen Scores steigt.
- Es geht nicht um absolute Scores, sondern um relative Scores zwischen Klassen.

4.9 Discriminant Analysis: generative Sicht

Logistische Regression modelliert direkt $\Pr(Y \mid X)$. Diskriminanzanalyse modelliert dagegen X innerhalb jeder Klasse und verwendet Bayes-Theorem, um $\Pr(Y \mid X)$ zu erhalten.

Bayes-Theorem für Klassifikation

$$\Pr(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{\ell=1}^K \pi_\ell f_\ell(x)}.$$

Bedeutung:

- $\pi_k = \Pr(Y = k)$: Prior-/Basiswahrscheinlichkeit der Klasse k .
- $f_k(x) = \Pr(X = x \mid Y = k)$: Dichte von X innerhalb Klasse k .
- Nenner: Normierung über alle Klassen, damit Wahrscheinlichkeiten zu 1 summieren.

Mechanik: Eine Klasse wird wahrscheinlich, wenn sie häufig ist (π_k groß) und wenn der beobachtete x -Wert unter dieser Klasse plausibel ist ($f_k(x)$ groß).

4.10 LDA bei einer Variable

Gaussian Density und LDA-Score bei $p = 1$

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_k}{\sigma_k} \right)^2 \right].$$

Bei LDA wird angenommen, dass alle Klassen dieselbe Varianz haben: $\sigma_k = \sigma$. Daraus ergibt sich der lineare Diskriminanzscore:

$$\delta_k(x) = x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k).$$

Mechanik:

- μ_k : Klassenmittelwert. Je näher x zum Klassenmittel liegt, desto plausibler die Klasse.
- σ^2 : gemeinsame Streuung. Große Streuung macht Trennung unschärfer.
- π_k : Prior. Häufigere Klassen bekommen Bonus über $\log(\pi_k)$.

Entscheidung: Wähle Klasse mit größtem $\delta_k(x)$.

Bei zwei Klassen und gleichen Priors $\pi_1 = \pi_2 = 0.5$ liegt die Entscheidungsgrenze bei:

$$x = \frac{\mu_1 + \mu_2}{2}.$$

Das ist intuitiv: Man entscheidet genau in der Mitte zwischen den Klassenmitteln.

4.11 LDA mit mehreren Variablen

Multivariate LDA

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log(\pi_k).$$

Mechanik:

- μ_k : Zentroid/Mittelwertvektor der Klasse.
- Σ : gemeinsame Kovarianzmatrix aller Klassen.
- Σ^{-1} : gewichtet Richtungen nach ihrer Streuung und Korrelation.

Warum linear? Weil alle Klassen dieselbe Kovarianzmatrix haben. Quadratische Terme in x kürzen sich heraus, daher sind Entscheidungsgrenzen linear.

LDA ist besonders nützlich, wenn n klein ist, Klassen ungefähr normalverteilt sind, Klassen gut getrennt sind oder mehr als zwei Klassen vorliegen. Außerdem liefert LDA niedrigdimensionale Diskriminanzplots.

4.12 QDA und Naive Bayes

QDA

$$\delta_k(x) = -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k) + \log(\pi_k) - \frac{1}{2} \log |\Sigma_k|.$$

Mechanik: Jede Klasse hat eigene Kovarianzmatrix Σ_k . Dadurch kürzen sich quadratische Terme nicht heraus. Entscheidungsgrenzen können gekrümmt/quadratisch sein.

Abhängigkeiten:

- flexibler als LDA, weil unterschiedliche Streuungsformen erlaubt sind;
- braucht mehr Daten, weil für jede Klasse eine Kovarianzmatrix geschätzt wird;
- bei kleinem n oder großem p kann QDA instabil werden.

Naive Bayes

$$f_k(x) = \prod_{j=1}^p f_{kj}(x_j).$$

Für Gaussian Naive Bayes:

$$\delta_k(x) \propto -\frac{1}{2} \sum_{j=1}^p \left[\frac{(x_j - \mu_{kj})^2}{\sigma_{kj}^2} + \log \sigma_{kj}^2 \right] + \log \pi_k.$$

Mechanik: Naive Bayes nimmt bedingte Unabhängigkeit der Features innerhalb jeder Klasse an. Dadurch muss keine volle Kovarianzmatrix geschätzt werden.

Warum nützlich bei großem p ? Weil die Zahl zu schätzender Parameter stark sinkt. Auch wenn die Unabhängigkeitsannahme unrealistisch ist, funktioniert die Klassifikation oft gut.

4.13 Logistic Regression vs. LDA

Für zwei Klassen kann LDA eine Log-Odds-Form erzeugen:

$$\log \left(\frac{p_1(x)}{1 - p_1(x)} \right) = c_0 + c_1 x_1 + \dots + c_p x_p.$$

Die Form ähnelt logistischer Regression. Der Unterschied liegt in der Schätzung:

- **Logistic Regression:** modelliert $\Pr(Y | X)$, discriminative learning.
- **LDA:** modelliert $\Pr(X, Y)$ über $\Pr(X | Y)\Pr(Y)$, generative learning.

In der Praxis können Ergebnisse ähnlich sein, aber bei kleinen Stichproben und plausiblen Normalannahmen kann LDA stabiler sein.

4.14 K-Nearest Neighbors

KNN-Idee

Für eine neue Beobachtung x_0 :

1. Suche die K nächsten Trainingspunkte.
2. Regression: mittlere Y -Werte dieser Nachbarn.
3. Classification: Mehrheitsklasse oder geschätzte Klassenanteile unter den Nachbarn.

Mechanik der Flexibilität:

- kleines K , z.B. $K = 1$: sehr flexibel, niedriger Bias, hohe Varianz;
- großes K : glatter, höherer Bias, niedrigere Varianz;
- Flexibilität steigt ungefähr mit $1/K$.

5 Kapitel 5: Resampling Methods

5.1 Warum Resampling?

Resampling-Methoden refitten ein Modell wiederholt auf Stichproben, die aus den Trainingsdaten gebildet werden. Sie liefern zusätzliche Informationen über Modellgüte und Unsicherheit. Die zwei zentralen Methoden aus dem Foliensatz sind:

- **Cross-validation:** Schätzung des Testfehlers und Auswahl der Modellkomplexität.
- **Bootstrap:** Schätzung von Standardfehlern, Bias und Konfidenzintervallen von Schätzern.

Kernidee

Wenn kein großes unabhängiges Testset vorhanden ist, versucht Resampling, die Idee von "neuen Daten" oder "wiederholtem Sampling" mit den vorhandenen Daten nachzuahmen.

5.2 Training Error vs. Test Error nochmal

Der Foliensatz betont erneut: Training Error kann den Test Error stark unterschätzen. Bei steigender Modellkomplexität fällt der Trainingsfehler meist immer weiter, während der Testfehler wegen Bias-Variance Trade-off eine U-Form zeigt.

5.3 Validation Set Approach

Validation Set Approach

Ablauf:

1. Teile Daten zufällig in Trainingsset und Validation-/Hold-out-Set.
2. Fitte Modell auf Trainingsset.
3. Berechne Fehler auf Validation Set.

Bei quantitativer Response verwendet man typischerweise MSE, bei kategorialer Response Misclassification Rate.

Mechanik: Validation-Daten wurden nicht zum Fitten verwendet. Deshalb liefern sie eine realistischere Fehlerabschätzung als Training Error.

Nachteile des Validation Set Approach

- Hohe Variabilität: Ergebnis hängt stark vom zufälligen Split ab.
- Das Modell wird nur auf einem Teil der Daten trainiert.
- Dadurch kann der Validation Error den Test Error des Modells überschätzen, das später auf allen Daten trainiert würde.

5.4 K-fold Cross-Validation

K-fold Cross-Validation - Ablauf

1. Teile Daten in K ungefähr gleich große Folds $C_1, \dots, C_K$.
2. Für jeden Fold k : Fitte Modell ohne C_k , also auf den anderen $K - 1$ Folds.
3. Berechne Vorhersagefehler auf dem ausgelassenen Fold C_k .
4. Mittlere die Fold-Fehler gewichtet nach Foldgröße.

Mechanik: Jede Beobachtung ist genau einmal Validation-Beobachtung und $K - 1$ -mal Teil eines Trainingssets.

K-fold CV für Regression

$$CV(K) = \sum_{k=1}^K \frac{n_k}{n} \text{MSE}_k, \quad \text{MSE}_k = \frac{1}{n_k} \sum_{i \in C_k} (y_i - \hat{y}_i)^2.$$

Bedeutung:

- C_k : Indexmenge der Beobachtungen in Fold k .
- n_k : Größe von Fold k .
- $\hat{y}_i$: Vorhersage für Beobachtung i , erzeugt von einem Modell, das i nicht im Training gesehen hat.

Mechanik: Jeder Fold liefert einen MSE. Die Gesamt-CV ist der gewichtete Durchschnitt der Fold-MSEs.

Abhängigkeiten:

- Größeres K bedeutet größere Trainingssets pro Fold, also weniger upward bias.
- Kleineres K bedeutet unabhängigere Trainingssets und oft niedrigere Varianz der CV-Schätzung.
- $K = 5$ oder $K = 10$ ist oft guter Kompromiss.

5.5 LOOCV

Leave-One-Out Cross-Validation

LOOCV ist der Spezialfall $K = n$. Jede Beobachtung wird einmal ausgelassen, das Modell wird auf $n - 1$ Beobachtungen gefittet und auf der ausgelassenen Beobachtung getestet.

$$CV(n) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i^{(-i)})^2.$$

Mechanik: $\hat{y}_i^{(-i)}$ ist die Vorhersage für i , wenn Modell i nicht gesehen hat.

LOOCV Shortcut bei Least Squares

$$CV(n) = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2.$$

Bedeutung:

- $\hat{y}_i$: fitted value aus dem Modell auf allen Daten.
- h_i : Leverage, Diagonale der Hat-Matrix.

Mechanik: Man muss nicht n Modelle fitten. Das normale Residuum $(y_i - \hat{y}_i)$ wird durch $1 - h_i$ geteilt. Beobachtungen mit hohem Leverage haben großen Einfluss; wenn man sie weglässt, ändert sich ihre Vorhersage stärker. Deshalb wird ihr Fehler hochskaliert.

Abhängigkeiten:

- Wenn h_i groß ist, ist $1 - h_i$ klein und der CV-Fehlerbeitrag groß.
- Hohe Leverage-Punkte werden also in LOOCV besonders sichtbar.

LOOCV Bias-Variance

LOOCV hat wenig upward bias, weil jedes Trainingsset fast so groß wie die Gesamtdaten ist. Aber die Fold-Schätzungen sind stark korreliert, weil sich die Trainingssets kaum unterscheiden. Daher kann LOOCV hohe Varianz haben. Deshalb sind $K = 5$ oder $K = 10$ oft praktischer.

5.6 Cross-Validation für Classification

K-fold CV für Klassifikation

$$CV_K = \sum_{k=1}^K \frac{n_k}{n} Err_k, \quad Err_k = \frac{1}{n_k} \sum_{i \in C_k} I(y_i \neq \hat{y}_i).$$

Mechanik: Für jeden Fold wird der Anteil falscher Klassifikationen berechnet. Dann wird über Folds gemittelt.

Abhängigkeiten:

- Je nach Klassengleichgewicht können Fold-Zusammensetzungen wichtig sein.
- Bei unausgeglichene Klassen kann stratified CV sinnvoll sein.

Geschätzte Standardabweichung der CV-Fehler

$$\widehat{SE}(CV_K) = \sqrt{\frac{1}{K} \frac{\sum_{k=1}^K (Err_k - \overline{Err})^2}{K-1}}.$$

Mechanik: Man behandelt die Fold-Fehler ungefähr wie K Beobachtungen und berechnet die Streuung des Durchschnitts.

Falle: Streng genommen ist das nicht vollständig gültig, weil Fold-Fehler nicht unabhängig sind: Trainingssets überlappen stark.

5.7 Cross-Validation richtig und falsch**Data Leakage bei CV**

Wenn man zuerst auf allen Daten Features auswählt und danach nur den Klassifikator cross-validiert, ist die CV-Schätzung zu optimistisch. Die Feature Selection hat bereits die Labels gesehen und ist Teil des Trainingsprozesses.

Falscher Ablauf:

1. Nutze alle Daten, um aus 5000 Prädiktoren die 100 mit größter Korrelation zu den Labels auszuwählen.
2. Cross-validiere nur Logistic Regression auf diesen 100 Features.

Richtiger Ablauf:

1. In jedem Fold: Feature Selection nur auf dem Trainingsanteil durchführen.
2. Danach Modell im Trainingsanteil fitten.
3. Auf ausgelassenem Fold testen.

Merksatz: Alles, was Labels verwendet, muss innerhalb der Cross-Validation-Schleife passieren.

5.8 Bootstrap: Grundidee

Bootstrap dient primär zur Schätzung von Unsicherheit: Standardfehler, Bias und Konfidenzintervalle. In der Realität können wir nicht beliebig viele neue Stichproben aus der Population ziehen. Bootstrap ersetzt die unbekannte Population durch die empirische Verteilung der beobachteten Daten.

Bootstrap-Ablauf

Gegeben Daten $Z = (z_1, \dots, z_n)$:

1. Ziehe mit Zurücklegen n Beobachtungen aus Z , erhalte Bootstrap-Datensatz Z^{*b} .
2. Berechne Schätzer $\hat{\theta}^{*b} = s(Z^{*b})$.
3. Wiederhole für $b = 1, \dots, B$.
4. Nutze die Verteilung von $\hat{\theta}^{*1}, \dots, \hat{\theta}^{*B}$ als Approximation der Sampling-Verteilung von $\hat{\theta}$.

Mechanik: Sampling mit Zurücklegen erzeugt neue Datensätze gleicher Größe. Manche Originalbeobachtungen erscheinen mehrfach, manche gar nicht.

5.9 Bootstrap-Standardfehler

Bootstrap Standard Error

$$\widehat{SE}_B(\hat{\theta}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*b} - \bar{\theta}^*)^2}, \quad \bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{*b}.$$

Mechanik: Man berechnet die Streuung der Bootstrap-Schätzungen. Diese Streuung approximiert, wie stark der ursprüngliche Schätzer zwischen echten Stichproben schwanken würde.

Abhängigkeiten:

- Größeres B stabilisiert die Monte-Carlo-Approximation.
- Größeres n führt oft zu kleineren Standardfehlern.
- Heterogene oder noisy Daten erzeugen größere Bootstrap-Streuung.

5.10 Bootstrap-Beispiel: Portfolio-Allokation

Risikominimierende Allokation zwischen zwei Assets

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}.$$

Bedeutung:

- Investiere Anteil α in Asset X , Anteil $1 - \alpha$ in Asset Y .
- $\sigma_X^2 = \text{Var}(X)$, $\sigma_Y^2 = \text{Var}(Y)$, $\sigma_{XY} = \text{Cov}(X, Y)$.

Mechanik: Die Formel minimiert $\text{Var}(\alpha X + (1 - \alpha)Y)$. Man wählt also die Mischung mit kleinster Portfoliovarianz.

Abhängigkeiten:

- Wenn Y sehr riskant ist (σ_Y^2 groß), steigt tendenziell α : mehr Gewicht auf X .
- Wenn X sehr riskant ist (σ_X^2 groß), sinkt tendenziell α : weniger Gewicht auf X .
- Wenn X und Y stark positiv kovariieren, sinkt der Diversifikationsvorteil.

Da σ_X^2 , σ_Y^2 und σ_{XY} unbekannt sind, schätzt man:

$$\hat{\alpha} = \frac{\hat{\sigma}_Y^2 - \hat{\sigma}_{XY}}{\hat{\sigma}_X^2 + \hat{\sigma}_Y^2 - 2\hat{\sigma}_{XY}}.$$

Bootstrap kann dann die Unsicherheit von $\hat{\alpha}$ schätzen.

5.11 Bootstrap Percentile Confidence Interval

Bootstrap Percentile Intervall

Für ein 90%-Intervall nimmt man z.B. das 5%- und 95%-Quantil der Bootstrap-Schätzungen:

$$\left[q_{0.05}(\hat{\theta}^*), q_{0.95}(\hat{\theta}^*) \right].$$

Mechanik: Die empirische Bootstrap-Verteilung ersetzt die unbekannte Sampling-Verteilung. Die mittleren 90% dieser Verteilung bilden ein approximatives Konfidenzintervall.

Interpretation: Bei wiederholter Anwendung auf neue Stichproben soll das Verfahren ungefähr die angegebene Coverage erreichen. Es ist eine Approximation, nicht exakt garantiert.

5.12 Warum Bootstrap nicht ideal für Prediction Error ist

Warum etwa zwei Drittel im Bootstrap-Sample erscheinen

Für eine bestimmte Beobachtung ist die Wahrscheinlichkeit, in einem einzelnen Ziehungsschritt nicht gezogen zu werden:

$$1 - \frac{1}{n}.$$

Nach n Ziehungen mit Zurücklegen:

$$\left(1 - \frac{1}{n} \right)^n \approx e^{-1} \approx 0.368.$$

Also ist die Wahrscheinlichkeit, mindestens einmal im Bootstrap-Sample zu erscheinen:

$$1 - 0.368 = 0.632.$$

Mechanik: Etwa 63.2% der Originalbeobachtungen erscheinen in einem Bootstrap-Datensatz, etwa 36.8% sind out-of-bag.

Bootstrap und Testfehler

Bootstrap-Samples überlappen stark mit dem Originaldatensatz. Wenn man Bootstrap-Trainingssamples nutzt und auf Originaldaten validiert, testet man teilweise auf Beobachtungen, die das Modell bereits gesehen hat. Dadurch wird der Prediction Error unterschätzt. Cross-Validation ist für Testfehler meist einfacher und attraktiver.

5.13 Block Bootstrap bei Zeitreihen

Bei Zeitreihen darf man nicht einfach einzelne Beobachtungen mit Zurücklegen ziehen, weil dadurch die zeitliche Abhängigkeit zerstört wird. Stattdessen zieht man Blöcke zusammenhängender Beobachtungen und setzt diese zu Bootstrap-Datensätzen zusammen. Die Resampling-Einheit muss also zur Datenstruktur passen.

5.14 Pre-validation

Pre-validation ist relevant, wenn ein adaptiv erzeugter Predictor, z.B. ein Biomarker-Score aus vielen Genen, fair mit festen klinischen Prädiktoren verglichen werden soll. Problem: Wenn der Biomarker-Predictor auf demselben Datensatz konstruiert und dann im selben Datensatz mit klinischen Variablen verglichen wird, ist er bevorteilt.

Mechanik der Pre-validation:

1. Teile Daten in K Folds.
2. Für jeden Fold: Lasse Fold weg, konstruiere den adaptiven Predictor nur auf den übrigen Daten.
3. Sage den ausgelassenen Fold vorher.
4. Am Ende hat jede Beobachtung eine vorvalidierte Prediction, die von einem Modell stammt, das diese Beobachtung nicht gesehen hat.
5. Vergleiche diese fairere Prediction mit festen Prädiktoren, z.B. in logistischer Regression.

5.15 Bootstrap vs. Permutation Tests

	Bootstrap	Permutation
Ziel	Standardfehler, Bias, Konfidenzintervalle.	p-Werte, Nullverteilung, False Discovery Rates.
Sampling aus	geschätzter Population / empirischer Verteilung.	geschätzter Nullverteilung.
Typische Frage	Wie unsicher ist $\hat{\theta}$?	Wie extrem ist ein Teststatistikwert unter H_0 ?
Mechanik	Ziehen mit Zurücklegen.	Labels/Werte permutieren unter Nullhypothese.

6 Formelkompass: Was hängt wovon ab?

Formel/Objekt	Wovon hängt es ab?	Mechanik/Interpretation
$Y = f(X) + \varepsilon$	Wahre Struktur f , beobachtete Features, Fehlerterm.	Trennt systematischen Teil und Zufall.
$f(x) = \mathbb{E}(Y \mid X = x)$	Populationsverteilung von Y gegeben $X = x$.	Optimaler Predictor bei quadratischem Verlust.
MSE_{Tr}	Trainingsdaten, Flexibilität, Fit.	Oft optimistisch; sinkt mit Komplexität.
MSE_{Te}	Generalisierung auf neue Daten.	Zentrale Größe für Vorhersagequalität.
Bias	Modellklasse und wahre Funktion.	Systematischer Fehler durch zu starres Modell.
Varianz	Flexibilität, Datenmenge, Rauschen.	Empfindlichkeit gegenüber Trainingsstichprobe.
RSS	Residuen im Trainingsdatensatz.	Summe quadrierter Abstände zur Modellvorhersage.
$\hat{\beta}_1$	Covariation von X, Y relativ zur Streuung von X .	Steigung: Veränderung von Y pro Einheit X .
$\text{SE}(\hat{\beta}_1)$	Fehlerstreuung σ^2 , Streuung von X , Stichprobengröße.	Unsicherheit der Steigung.
R^2	Anteil erklärte Variation.	Vergleich gegen Mittelwertmodell.
Interaktion $\beta_3 X_1 X_2$	gemeinsamer Effekt zweier Variablen.	Effekt von X_1 hängt von X_2 ab.
Logit	Wahrscheinlichkeit p .	Transformiert $(0, 1)$ auf $\mathbb{R}$.

Odds Ratio	logistischer Koeffizient.	Multiplikativer Effekt auf Odds.
LDA-Score	Klassenmittel, gemeinsame Kovarianz, Prior.	Klassifiziert nach größtem Diskriminanzscore.
QDA-Score	Klassenmittel, klassenspezifische Kovarianz, Prior.	Erlaubt gekrümmte Entscheidungsgrenzen.
KNN-Flexibilität	K .	Kleines K : flexibel; großes K : glatt.
$CV(K)$	Fold-Aufteilung, Modellklasse, Fehlermaß.	Schätzt Testfehler durch wiederholtes Auslassen.
Bootstrap-SE	Streuung der Bootstrap-Schätzungen.	Schätzt Sampling-Unsicherheit.

7 Prüfungsmuster: Typische Fragen und Kernantworten

1. Warum ist Test Error wichtiger als Training Error?

Training Error bewertet das Modell auf Daten, die es bereits gesehen hat. Er kann stark unterschätzt sein, besonders bei flexiblen Modellen. Test Error misst die erwartete Leistung auf neuen Beobachtungen und ist deshalb die relevante Größe für Generalisierung.

2. Erkläre Bias-Variance Trade-off.

Mit steigender Flexibilität sinkt meist der Bias, weil das Modell mehr wahre Struktur erfassen kann. Gleichzeitig steigt meist die Varianz, weil das Modell stärker auf Zufall im Trainingsdatensatz reagiert. Der Testfehler ist Summe aus Varianz, Bias² und irreduziblem Fehler. Optimale Flexibilität liegt dort, wo diese Summe minimal ist.

3. Warum kann lineare Regression für Klassifikation problematisch sein?

Bei $Y \in \{0, 1\}$ kann $E(Y | X) = Pr(Y = 1 | X)$ zwar als Wahrscheinlichkeit interpretiert werden, aber lineare Regression kann Werte unter 0 oder über 1 liefern. Außerdem ist sie bei mehr als zwei ungeordneten Klassen unpassend, weil numerische Kodierung künstliche Ordnung erzeugt.

4. Was ist der Unterschied zwischen logistischen Koeffizienten und Wahrscheinlichkeitsänderungen?

Logistische Koeffizienten wirken linear auf Log-Odds. e^{β_j} ist eine Odds Ratio. Die Änderung der Wahrscheinlichkeit ist nicht konstant, sondern hängt vom Ausgangsniveau der Wahrscheinlichkeit ab.

5. Wann ist LDA gegenüber Logistic Regression attraktiv?

LDA kann bei kleinen Stichproben stabiler sein, wenn die Normalverteilungsannahme innerhalb Klassen plausibel ist. Außerdem ist LDA natürlich für mehrere Klassen und liefert Diskriminanzplots.

6. Warum muss Feature Selection in die CV-Schleife?

Weil Feature Selection Labels benutzt und damit Training ist. Wenn man Features vor CV auf allen Daten auswählt, enthält das Validation Fold bereits indirekte Information aus den Labels. Das führt zu Data Leakage und zu optimistisch geschätztem Testfehler.

7. Warum ist Bootstrap gut für Standardfehler, aber nicht einfach für Testfehler?

Bootstrap approximiert die Sampling-Verteilung eines Schätzers gut, indem aus der empirischen Verteilung gezogen wird. Für Testfehler ist das Problem, dass Bootstrap-Samples stark mit den Originaldaten überlappen. Validierung auf überlappenden Daten unterschätzt den Prediction Error.

8 Mini-Glossar

Begriff	Bedeutung
Feature / Predictor / Covariate	erklärende Variable X_j .
Response / Outcome / Target	Zielvariable Y .
Training Set	Daten, auf denen Modell geschätzt wird.
Validation Set	zurückgehaltener Teil zur Modellwahl/Fehlerschätzung.
Test Set	unabhängige Daten zur finalen Bewertung.
Residual	Beobachtet minus vorhergesagt: $e_i = y_i - \hat{y}_i$.
Overfitting	Modell lernt Rauschen im Training.
Underfitting	Modell ist zu simpel und verpasst echte Struktur.
Bias	systematische Verzerrung.
Variance	Schwankung des Schätzers über Trainingsstichproben.
Irreducible Error	Fehler, der auch bei perfektem Modell bleibt.
Leverage	Einfluss eines Punktes durch ungewöhnliche X -Werte.
Odds	Verhältnis Ereigniswahrscheinlichkeit zu Gegenwahrscheinlichkeit: $p/(1-p)$.
Logit	Logarithmus der Odds.
Prior π_k	Basiswahrscheinlichkeit einer Klasse.
Density $f_k(x)$	Plausibilität von x innerhalb Klasse k .
Fold	Teilmenge bei Cross-Validation.
Out-of-bag	Beobachtungen, die in einem Bootstrap-Sample nicht gezogen wurden.

9 Quellenbasis

Diese Lernfassung basiert auf den hochgeladenen Foliensätzen:

- Ch1_Inroduction.pdf - Einführung, supervised/unsupervised learning, Beispiele, Statistical Learning vs. Machine Learning.
- Ch2_Statistical_Learning.pdf - Grundmodell, $f(X)$, Training/Test Error, Flexibilität, Bias-Variance Trade-off, Bayes Classifier, KNN.
- Ch3_Linear_Regression.pdf - Simple und multiple lineare Regression, OLS, Standardfehler, Modellgüte, Variablenselektion, qualitative Prädiktoren, Interaktionen, Polynomial Regression.

- Ch4_Classification.pdf - Klassifikation, logistische Regression, Maximum Likelihood, Case-Control Sampling, Multiclass Logistic Regression, LDA/QDA/Naive Bayes, Logistic vs. LDA.
- 05-Ch5_Resampling_Methods.pdf - Validation Set Approach, K-fold CV, LOOCV, Cross-Validation für Klassifikation, Data Leakage, Bootstrap, Bootstrap-SE, Percentile CI, Prediction Error mit Bootstrap, Pre-validation, Bootstrap vs. Permutation.